

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

INSTITUTO DE INVESTIGACIONES EN MATEMÁTICAS  
APLICADAS Y EN SISTEMAS

ESPECIALIZACIÓN EN ESTADÍSTICA APLICADA

Modelos de Ecuaciones Estructurales

Adicción juvenil y padres alcohólicos

Jesus Alberto Urrutia Camacho (urcajeal@gmail.com)

Ciudad de México

14 de junio de 2021

El Proyecto para el Desarrollo de la familia y el adolescente ( *The Adolescent and Family Development Project*, en los Estados Unidos) diseñó una investigación que tiene por objetivo "evaluar la asociación entre el alcoholismo de los padres y el uso de sustancias en adolescentes y psicopatologías" (Zamora, 2021). Para tal propósito, se levantó una muestra aleatoria integrada por 316 adolescentes entre 10 – 16 años de edad. Cabe destacar que el estudio fue diseñado para evaluar la asociación entre el alcoholismo de los padres y uso de sustancias en adolescentes y psicopatología. Además, la muestra es compuesta íntegramente por variables medidas, por lo que se realiza un Análisis de Trayectoria o *Path Analysis*, para comprobar la validez de esta teoría.


**Cuadro 1:** Variables del modelo de adicciones

Variable	Sigla	Notación	Interpretación
Peer	$Y_{peer}$	Endógena continua	Consumo de sustancia adictivas por compañeros
Negaff	$Y_{negaff}$	Endógena continua	Ansiedad y depresión en adolescentes
Stress	$Y_{stress}$	Endógena continua	Percepción de Eventos estresantes en vida adolescente
Emotion	$Y_{emotion}$	Endógena continua	Percepción de Falta de control emocional en adolescentes
Coa	$Y_{coa}$	Exógena binaria	Padres alcohólicos ( $X : x = 1$ , <i>sí alcohólicos</i> )
Gen	$Y_{gen}$	Exógena binaria	Sexo del adolescente ( $X : x = 1$ , <i>Masculino</i> )
Age	$Y_{age}$	Exógena discreta	Edad adolescente

Específicamente, se parte de la siguiente teorización. Los padres alcohólicos ( *coa* ) inciden en vidas con efectos estresantes ( *stress* ) para las y los hijos, lo que aumenta la percepción de depresión y ansiedad en los adolescentes ( *negaff* ). Además, se considera que las familias alcohólicas provoca en los jóvenes falta de control emocional ( *emotion* ), lo que incrementa depresión y ansiedad ( *negaff* ) en estos últimos. Entonces, se podría argüir que eventos estresantes ( *stress* ) tiene una relación no direccional con falta de control emocional ( *emotion* ). En complemento a lo anterior, los resultados negativos, como ansiedad y depresión, generan tasas altas de convivencia con compañeros que consumen drogas ( *peer* ), lo que podría generar adicciones. Finalmente, se considera que el estrés ( *stress* ) y la dificultad emocional ( *emotion* ) son predichas por la edad ( *age* ) y el sexo ( *gen* ). Donde las variables exógenas están correlacionadas.

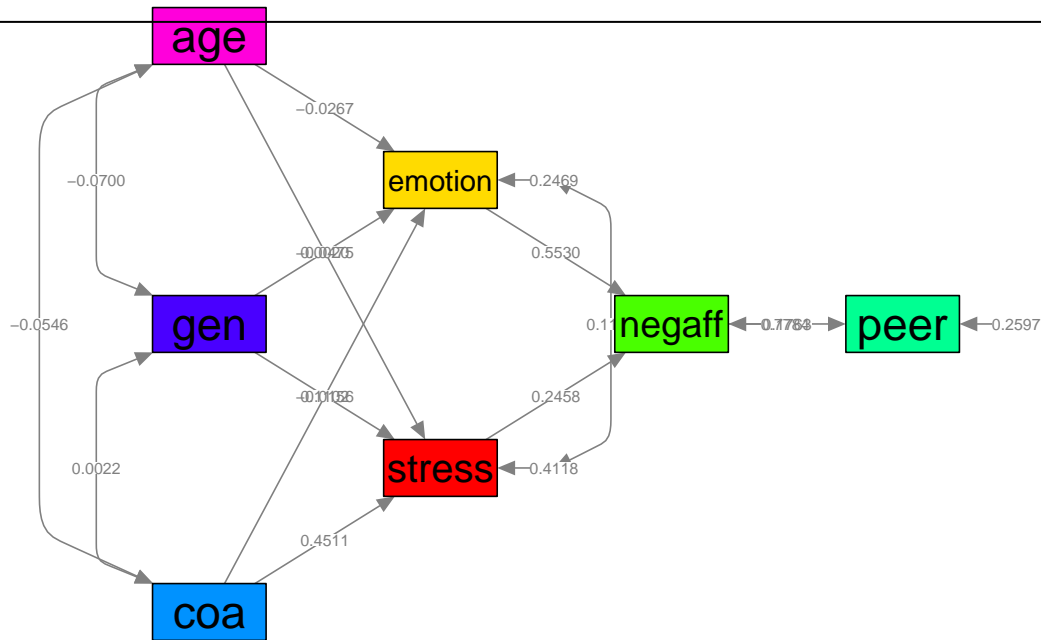
Dado que se cuenta con la base de datos se procede a hacer estadística descriptiva. Todas las variables son numéricas, pero *coa* y *gen* son variables dicotómicas, donde  $P(X|x_{coa} = 0 : \text{Padres no alcohólicos})$ , y  $P(X|x_{gen} = 0 : \text{Mujer})$ , respectivamente. Además, las variables, *Stress*, *emotion*, *negaff* y *peer* son variables continuas, que parecen ser tasas o índices, ya que tienen valores positivos y menores de 6. Cabe destacar que no se cuenta con un diccionario de datos.

A continuación se muestran dos correlogramas. Cabe señalar que no hay ninguna correlación significativa. El primer correlograma integra a las correlaciones biserial, tetracórica y de Pearson. Mientras que el segundo solamente usa la última correlación. Se evidencia, que las correlaciones para variables dicotómicas aumentaron (es decir, se intensificó su color).



## 1. Diagramar modelo

Consumo sustancia entre adolescentes dado por padres alcohólicos y psicopatología



## 2. Escribirlo matricialmente

$$\begin{aligned}
 Y_{stres} &= 0Y_{stres} + 0Y_{emo} + 0Y_{neg} + 0Y_{peer} + \gamma_{1,1}X_{coa} + \gamma_{1,2}X_{gen} + \gamma_{1,3}X_{age} + \varsigma_1 \\
 Y_{emo} &= 0Y_{stres} + 0Y_{emo} + 0Y_{neg} + 0Y_{peer} + \gamma_{2,1}X_{coa} + \gamma_{2,2}X_{gen} + \gamma_{2,3}X_{age} + \varsigma_2 \\
 Y_{neg} &= \beta_{1,1}Y_{stres} + \beta_{1,2}Y_{emo} + 0Y_{neg} + 0Y_{peer} + 0X_{coa} + 0X_{gen} + 0X_{age} + \varsigma_3 \\
 Y_{emo} &= 0Y_{stres} + 0Y_{emo} + \beta_{2,1}Y_{neg} + 0Y_{peer} + 0X_{coa} + 0X_{gen} + 0X_{age} + \varsigma_4
 \end{aligned}$$

$$\begin{bmatrix} Y_{stres} \\ Y_{emo} \\ Y_{neg} \\ Y_{peer} \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ \beta_{1,1} & \beta_{1,2} & 0 & 0 \\ 0 & 0 & \beta_{2,1} & 0 \end{bmatrix} \begin{bmatrix} Y_{stres} \\ Y_{emo} \\ Y_{neg} \\ Y_{peer} \end{bmatrix} + \begin{bmatrix} \gamma_{1,1} & \gamma_{1,2} & \gamma_{1,3} \\ \gamma_{2,1} & \gamma_{2,2} & \gamma_{2,3} \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} X_{coa} \\ X_{gen} \\ X_{age} \end{bmatrix} + \begin{bmatrix} \varsigma_1 \\ \varsigma_2 \\ \varsigma_3 \\ \varsigma_4 \end{bmatrix}$$

## 3. Escribir matrices involucradas en modelo

Además, respectivamente, cada matriz presentada con anterioridad puede se expresada como:  $Y = BY + \Gamma x + \zeta$

$$\Psi = \begin{bmatrix} \psi_{1,1} & 0 & 0 & 0 \\ \psi_{2,1} & \psi_{2,2} & 0 & 0 \\ 0 & 0 & \psi_{3,1} & 0 \\ 0 & 0 & 0 & \psi_{4,1} \end{bmatrix} \quad \Phi = \begin{bmatrix} \phi_{1,1} & 0 & 0 \\ \phi_{2,1} & \phi_{2,2} & 0 \\ \phi_{3,1} & \phi_{3,2} & \phi_{3,3} \end{bmatrix}$$

Cabe destacar que  $\Psi$  representa la matriz de correlación entre variables endógenas ( $Y_i$ ). Mientras que la matriz de  $\Phi$  presenta a la correlación entre variables exógenas ( $X_i$ ). Cabe destacar que  $\Psi_{2,1}$  es la correlación que existe entre  $Y_{stress}$  y  $Y_{emotion}$ , en función de la teoría de adicciones.

## 4. Ajuste del modelo

La estimación del modelo emplea el método bootstrap, como alternativa a las restricciones del supuesto de normalidad por el método delta. Lo anterior requiere que la muestra esté disponible para realizar el remuestreo (Hallquist, 2019).

Además, se emplean la paquetería *lavaan* como principal instrumento de ajuste computaciones, y se usa la información de la matriz de correlación de Pearson, biserial y tetracórica, según corresponda el tipo de variable. Se tienen 20 grados de libertad, lo que corresponde a las parte de información. A continuación se muestra el código empleado.

```
\begin{minted}[frame=lines, linenos, fontsize=\small]
{r}

#Matriz de correlaciones
CorMid <- '
1.0
-0.09456621 1.0
0.01400000 0.12159467 1.0
0.41430068 -0.01973430 -0.01121133 1.0
0.14398422 -0.08074436 -0.04854675 0.3664796 1.0
0.10279496 0.15121667 -0.12520711 0.2807905 0.35387788 1.0
0.20542024 0.39572236 -0.10289694 0.2402493 0.13368237 0.3145978 1.0
'

#Matriz cuadrada de correlaciones con nombres de variables en columna
comp.cor1 <- getCov(CorMid, sds = NULL, names = c("coa", "age", "gen", "stress", "emotion", "negaff", "peer"))

#Modelo teórico
mod1 <- '
stress ~ a*coa + b*gen + c*age
emotion ~ e*coa + f*gen + g*age
negaff ~ x*stress + y*emotion
peer ~ z*negaff

emotion ~~ stress
coa ~~ gen
gen ~~ age
coa ~~ age

#Efectos indirectos
NegStresCoa := x*a
NegStresGen := x*b
```

```

NegStresAge := x*c
NegEmoCoa := y*e
NegEmoGen := y*f
NegEmoAge := y*g
PeNegStresCoa := z*x*a
PeNegEmoCoa := z*y*e

#Efetos Totales
T1 := a + x*a + z*x*a
T2 := a + y*e + z*y*e
'

n <- length(bd$coa)

#ajuste del modelo mediante bootstrap
sem1 <- sem(mod1, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")

summary(sem1, fit.measures = TRUE, standardized=T, rsquare = T)
#Brinda los estimadores estandarizados y el aporte de variabilidad de cada variable al modelo

\end{minted}

```

```

## lavaan 0.6-8 ended normally after 31 iterations
##
##      Estimator                      ML
##      Optimization method          NLMINB
##      Number of model parameters      20
##
##      Number of observations          316
##
## Model Test User Model:
##
##      Test statistic                  81.173
##      Degrees of freedom              8
##      P-value (Chi-square)           0.000
##
## Model Test Baseline Model:
##
##      Test statistic                  255.823
##      Degrees of freedom              21
##      P-value                        0.000
##
## User Model versus Baseline Model:
##
##      Comparative Fit Index (CFI)      0.688
##      Tucker-Lewis Index (TLI)        0.182
##
## Loglikelihood and Information Criteria:
##
##      Loglikelihood user model (H0)    -2179.133
##      Loglikelihood unrestricted model (H1) -2138.547
##
##      Akaike (AIC)                    4398.267
##      Bayesian (BIC)                   4473.382

```

```

## Sample-size adjusted Bayesian (BIC)          4409.947
##
## Root Mean Square Error of Approximation:
##
## RMSEA                                          0.170
## 90 Percent confidence interval - lower        0.138
## 90 Percent confidence interval - upper        0.205
## P-value RMSEA <= 0.05                        0.000
##
## Standardized Root Mean Square Residual:
##
## SRMR                                          0.095
##
## Parameter Estimates:
##
## Standard errors                               Bootstrap
## Number of requested bootstrap draws          1000
## Number of successful bootstrap draws          1000
##
## Regressions:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## stress ~
##   coa      (a)    0.451   0.072   6.286   0.000   0.451   0.331
##   gen      (b)   -0.016   0.073  -0.216   0.829  -0.016  -0.011
##   age      (c)    0.002   0.026   0.075   0.940   0.002   0.004
## emotion ~
##   coa      (e)    0.110   0.055   1.986   0.047   0.110   0.110
##   gen      (f)   -0.048   0.058  -0.818   0.414  -0.048  -0.047
##   age      (g)   -0.027   0.021  -1.256   0.209  -0.027  -0.077
## negaff ~
##   stress   (x)    0.246   0.096   2.566   0.010   0.246   0.175
##   emotion  (y)    0.553   0.115   4.807   0.000   0.553   0.290
## peer ~
##   negaff   (z)    0.176   0.033   5.275   0.000   0.176   0.315
##
## Covariances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .stress ~~
##   .emotion      0.112   0.018   6.070   0.000   0.112   0.352
## coa ~~
##   gen          0.002   0.014   0.152   0.879   0.002   0.009
## gen ~~
##   age        -0.070   0.040  -1.754   0.079  -0.070  -0.097
## coa ~~
##   age        -0.055   0.040  -1.367   0.171  -0.055  -0.076
##
## Variances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .stress      0.412   0.041  10.060   0.000   0.412   0.890
## .emotion      0.247   0.017  14.787   0.000   0.247   0.979
## .negaff       0.778   0.071  10.966   0.000   0.778   0.848
## .peer         0.260   0.033   7.962   0.000   0.260   0.901
## coa           0.249   0.002 138.094   0.000   0.249   1.000
## gen           0.249   0.002 102.758   0.000   0.249   1.000

```

```
##      age      2.095      0.125      16.781      0.000      2.095      1.000
##
## Defined Parameters:
##      Estimate Std.Err z-value P(>|z|) Std.lv Std.all
##      NegStresCoa      0.111      0.046      2.406      0.016      0.111      0.058
##      NegStresGen     -0.004      0.019     -0.198      0.843     -0.004     -0.002
##      NegStresAge      0.000      0.007      0.068      0.946      0.000      0.001
##      NegEmoCoa       0.061      0.034      1.789      0.074      0.061      0.032
##      NegEmoGen     -0.026      0.034     -0.773      0.439     -0.026     -0.014
##      NegEmoAge     -0.015      0.012     -1.278      0.201     -0.015     -0.022
##      PeNegStresCoa    0.020      0.010      2.006      0.045      0.020      0.018
##      PeNegEmoCoa     0.011      0.007      1.635      0.102      0.011      0.010
##      T1              0.582      0.105      5.562      0.000      0.582      0.407
##      T2              0.182      0.094      1.941      0.052      0.182      0.151
```

La estimación de los parámetros se muestra a continuación:

## 5. Verifique lo adecuado del ajuste

A fin de verificar el ajuste del modelo, se deben considerar los índices de bondad de ajuste (GoF, por sus siglas en Inglés).

En el modelo propuesto, la prueba de la  $\chi^2$  rechaza la hipótesis nula, donde  $H_o : \text{Modelo Sí Ajusta}$ , es decir que el modelo no ajusta a los datos, debido a que el Pvalor es mucho menor que la significancia. Lo anterior se puede visualizar en la sección de *User Model*. Cabe agregar que el modelo basal es mucho peor que el propuesto, donde este es el modelo nula, donde no hay asociación entre variables, ya que el *Test statistic* representa el valor de la  $\chi^2$ .

```
\begin{minted}[frame=lines, linenos, fontsize=\small]
{r}
```

User Model:

```
Test statistic      81.173
Degrees of freedom      8
P-value (Chi-square)  0.000
```

Model Test Baseline Model:

```
Test statistic      255.823
Degrees of freedom     21
P-value             0.000
```

```
\end{minted}
```

**Cuadro 2:** Índices de ajuste del modelo

CFI	TLI	RMSEA	Pvalue	RMSEA	SRMR
0.688	0.182	0.17	0.0		0.095

- CFI: Es el *Comparative Fit Index*, en que este modelo tiene un valor muy pequeño. Por lo que se puede sostener que el modelo es muy malo. Además, para valores "mayor 0.97 es indicativo de un buen ajuste en relación con el modelo de independencia"(Zamora, 2021).



- NNFI ,también conocido como TLI, es decir, "índice de ajuste no normalizado (NNFI), también conocido como el índice de Tucker-Lewis (TLI)". Este modelo tiene un valor muy pequeño, lo que indica que el modelo es malo. Ya que "valores superiores a 0.95 pueden interpretarse como un ajuste aceptable"(Zamora, 2021).
- RMSEA, significa error cuadrático medio de aproximación de la raíz. Donde valores mayores a 0.1, implican valores de ajuste mediocres, por lo que este modelo no es bueno.
- Pvalor RMSEA, implica que el valor puntual de RMSAE sea contenido por un intervalo de confianza del 95
- SRMR, o índice de la raíz del cuadrado medio del residuo estandarizado, "valores de SRMR menores a 0.05 evidencian un buen ajuste y que menores a 0.10 pueden interpretarse como un ajuste aceptable"(Zamora, 2021). Por lo que se puede afirmar que este modelo tiene un ajuste aceptable.

En adición a lo anterior, en la función *rsquare* brinda la medida de variabilidad que aporta cada variable independiente al modelo. El siguiente recuadro muestra el estimado. Se podría esperar que las variables en suma alcancen el 1 de variabilidad explicada, pero lo que explican es muy bajo. A lo más, la variable *negaff* aporta poco más del 15 %.

```
\begin{minted}[frame=lines, linenos, fontsize=\small]
{r}
```

R-Square:

	Estimate
stress	0.110
emotion	0.021
negaff	0.152
peer	0.099

```
\end{minted}
```

Por lo anterior es posible afirmar que el modelo, en general, no ajusta. Es decir, los datos no respaldan la teoría propuesta. Entonces, se sugiere modificar las relaciones entre variables, siempre y cuando esté mediada por conocimiento de área experta.

Dado lo anterior se propone reestructurar el modelo en función de conocimiento experto. Donde las únicas variables que medien el modelo sean el hecho que los padres sean alcohólicos ( *coa* ), su efecto sobre eventos estresantes ( *stres* ) y sobre falta de control de emociones ( *emotion* ) ambas en los adolescentes. Y la incidencia de las anteriores sobre ansiedad y depresión ( *negaff* ), y su vez sobre el consumo de sustancia ( *peer* ).

Entonces, la graficación del modelo quedaría como sigue. Respecto a la forma de estimación del modelo sigue los mismo procesos que el anterior modelo. Y a continuación se muestran los índices de bondad de ajuste.

## 6. Interpretar efectos directos, indirectos, totales y concluir

El siguiente *output* de R muestra la estimación de los coeficientes, las covarianzas y varianzas de los parámetros estimados. Como se puede observar, solamente *coa* tiene una relación lineal significativa para la variable de Stress y Emotion, *stress* y *emotion* a su vez son significativas para la variable Negaff, y finalmente *negaff* es significativa para Peer, todas con un nivel de confianza del 95 %. Cabe recordar que la salida de *Std.all* se interpreta como todas las variables estandarizadas, y *std.lv* como la estandarización solamente de variables latentes.

```
\begin{minted}[frame=lines, linenos, fontsize=\small]
{r}
```

Regressions:

		Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
stress ~							
coa	(a)	0.451	0.070	6.457	0.000	0.451	0.331
gen	(b)	-0.016	0.071	-0.219	0.826	-0.016	-0.011
age	(c)	0.002	0.026	0.076	0.939	0.002	0.004
emotion ~							
coa	(e)	0.110	0.056	1.956	0.050	0.110	0.110
gen	(f)	-0.048	0.056	-0.847	0.397	-0.048	-0.047
age	(g)	-0.027	0.021	-1.287	0.198	-0.027	-0.077
negaff ~							
stress	(x)	0.246	0.094	2.602	0.009	0.246	0.175
emotion	(y)	0.553	0.115	4.792	0.000	0.553	0.290
peer ~							
negaff	(z)	0.176	0.033	5.412	0.000	0.176	0.315

\end{minted}

Respecto a las asociaciones entre variables, sólomente la relación entre eventos estresantes y la falta de control de emociones ( *stress* y *emotion* ) es significativa al 95 % .

\begin{minted}[frame=lines, linenos, fontsize=\small]{r}

Covariances:

		Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stress ~~							
.emotion		0.112	0.018	6.300	0.000	0.112	0.352
coa ~~							
gen		0.002	0.013	0.163	0.870	0.002	0.009
gen ~~							
age		-0.070	0.039	-1.775	0.076	-0.070	-0.097
coa ~~							
age		-0.055	0.039	-1.400	0.162	-0.055	-0.076

\end{minted}

La sección de **Interceptos** se interpreta como un  $\beta_0$  en una regresión lineal. Es decir, dado que la variable independiente es cero, cuál es el valor de la respuesta. Por ejemplo, cuando todas las variables son 0, el coeficiente de peer es  $Y_{peer} = -0.22$ . Es decir, cuando los padres no son alcohólicos, se es mujer de 0 años, y no hay enfermedades psicológicas, el riesgo de relacionarse con sustancias adictivas es negativo.

\begin{minted}[frame=lines, linenos, fontsize=\small]{r}

Intercepts:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stress	0.687	0.332	2.069	0.039	0.687	1.010
.emotion	2.341	0.276	8.485	0.000	2.341	4.663
.negaff	1.527	0.201	7.596	0.000	1.527	1.594
.peer	-0.118	0.089	-1.324	0.185	-0.118	-0.220
coa	0.525	0.029	18.422	0.000	0.525	1.052
gen	0.538	0.027	19.686	0.000	0.538	1.079
age	12.718	0.081	156.060	0.000	12.718	8.788

\end{minted}

Todas las varianzas son significativas.

```
\begin{minted}[frame=lines, linenos, fontsize=\small]
{r}
```

Variances:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
.stress	0.412	0.040	10.226	0.000	0.412	0.890
.emotion	0.247	0.017	14.738	0.000	0.247	0.979
.negaff	0.778	0.070	11.073	0.000	0.778	0.848
.peer	0.260	0.032	8.113	0.000	0.260	0.901
coa	0.249	0.002	134.489	0.000	0.249	1.000
gen	0.249	0.002	105.258	0.000	0.249	1.000
age	2.095	0.123	17.001	0.000	2.095	1.000

```
\end{minted}
```

Respecto a la interpretación de los **efectos indirectos**, si se menos estricto con la confianza del intervalo y la significancia es del 90 %, sólomente los efectos indirectos mediados entre la variable de padres alcohólicos, estrés, falta de control emocional, y percepción de ansiedad y depresión son significativas.

**Cuadro 3:** Efecto indirecto al 90 % de confianza

Computada	Interpretación	Valor
NegStresCoa	Efecto indirecto entre NEGAFF y COA, a través STRESS	0.058
NegEmoCoa	Efecto indirecto entre NEGAFF y COA, a través de EMOTIO	0.032
PeNegStresCoa	Efecto indirecto entre PEER y COA, a través de STRESS y NEGAFF	0.018
PeNegEmoCoa	Efecto indirecto entre PEER y COA, a través de EMOTION y NEGAFF	0.01

Lo anterior implica que exclusivamente los efectos indirectos mostrados son significativos. Es decir, sí hay una asociación entre el hecho de que los padres sean alcohólicos y la vinculación de adolescentes con pares adictos, y su posible drogadicción. Además, la anterior teorización está mediada por las variables de salud mental, como son eventos de vida estresantes, dificultad de controlar emociones y la percepción de ansiedad y depresión en jóvenes. Sin embargo, el modelo rechaza que las variables como edad y sexo, tengan un efectos directo sobre *Stress* y *emotion*, y edad y sexo tengan efecto indirecto sobre *peer* dado que sean medidas por el modelo propuesto.

Además, respecto a la magnitud de las asociaciones, es posible afirmar que el efecto indirecto entre el hecho de alcoholismo en padres y la percepción de ansiedad/depresión en jóvenes mediado por el estrés (0.058), es casi el doble que el efecto indirecto entre el hecho de alcoholismo en padres y la percepción de ansiedad/depresión en jóvenes mediado por el falta de control emocional (0.032). Lo que podría hacer pensar que eventos estresantes *stress* genera más afiliación a sustancias adictiva. Lo anterior se reafirma con el efecto indirecto entre el alcoholismo de padres y la cercanía de sustancia adictivas mediado por estrés y ansiedad/depresión, con un efecto indirecto más alto (0.018) que el efecto de entre el alcoholismo de padres y la cercanía de sustancia adictivas mediado por falta de control emocional y ansiedad/depresión (0.01). Entonces, se podría concluir que *stress* y *coa* sí inciden de forma indirecta en *peer*.

```
\begin{minted}[frame=lines, linenos, fontsize=\small]
{r}
```

Defined Parameters:

Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
----------	---------	---------	---------	--------	---------

NegStresCoa	0.111	0.048	2.290	0.022	0.111	0.058
NegStresGen	-0.004	0.020	-0.190	0.849	-0.004	-0.002
NegStresAge	0.000	0.007	0.068	0.946	0.000	0.001
NegEmoCoa	0.061	0.034	1.787	0.074	0.061	0.032
NegEmoGen	-0.026	0.033	-0.785	0.432	-0.026	-0.014
NegEmoAge	-0.015	0.011	-1.338	0.181	-0.015	-0.022
PeNegStresCoa	0.020	0.010	1.952	0.051	0.020	0.018
PeNegEmoCoa	0.011	0.006	1.660	0.097	0.011	0.010

\end{minted}

Respecto a la interpretación de los **efectos totales**, estos se definen como la suma entre efectos directos e indirectos. En esta sección, los efectos computados fueron la ruta que se indica a continuación:

$$T1 := coa - stress + coa * stress * negaff + coa * stress * negaff * peer \quad T2 := coa - emotion + coa * emotion * negaff + coa * emotion * negaff * peer$$

Con una confianza del 95 % solamente el efecto total (T1) es significativo, es decir que la suma de efectos directos e indirectos sí representan una asociación que se ajusta al modelo, esto para la ruta entre *coa*, *stress*, *negaff*, y *peer*.

\begin{minted}[frame=lines, linenos, fontsize=]

Defined Parameters:						
	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
T1	0.582	0.103	5.658	0.000	0.582	0.407
T2	0.182	0.095	1.918	0.055	0.182	0.151

Entonces, dalo lo anterior es posible afirmar que el modelo propuesto por la teoría no ajusta con los datos. Por tanto, se propone un nuevo modelo basado en el conocimiento de área que propone excluir al sexo *gen* y la edad *age* como predictoras directas del estrés y falta de control emocional. Es decir, que el único afecto directo entre las exógenas provenga de si los padres son alcohólicos o no *coa*.

Finalmente, para ajustar aún más el modelo se usa la función **modindices()** para sugerir relaciones significativas. Se integran las relaciones con un valor de  $\chi^2_1 = 6 > \chi^2_{1,0.95} = 3.84$ . Cabe destacar que este criterio debe de ser mediado exclusivamente con conocimiento de área, en esta sección se integran las relaciones de forma ilustrativa. Y las relaciones directas que se desprenden son entre *coa* y *age* hacia *peer* y de forma exclusiva entre *age* hacia *Negaff*. El modelo graficado se muestra a continuación:

```
mod2v <- '
stress ~ a*coa
emotion ~ e*coa
negaff ~ x*stress + y*emotion
peer ~ z*negaff
peer ~ i*coa
peer ~ j*age
negaff ~ k*age

emotion ~~ stress
age ~~ coa
'

sem3v <- sem(mod2v, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")
summary(sem3v, fit.measures = TRUE, standardized=T)
```

```
## lavaan 0.6-8 ended normally after 29 iterations
##
##      Estimator          ML
##      Optimization method NLMINB
```

```

##      Number of model parameters                16
##
##      Number of observations                    316
##
## Model Test User Model:
##
##      Test statistic                            10.044
##      Degrees of freedom                        5
##      P-value (Chi-square)                     0.074
##
## Model Test Baseline Model:
##
##      Test statistic                            249.979
##      Degrees of freedom                        15
##      P-value                                  0.000
##
## User Model versus Baseline Model:
##
##      Comparative Fit Index (CFI)               0.979
##      Tucker-Lewis Index (TLI)                 0.936
##
## Loglikelihood and Information Criteria:
##
##      Loglikelihood user model (H0)             -1918.056
##      Loglikelihood unrestricted model (H1)      -1913.033
##
##      Akaike (AIC)                             3868.111
##      Bayesian (BIC)                           3928.203
##      Sample-size adjusted Bayesian (BIC)       3877.455
##
## Root Mean Square Error of Approximation:
##
##      RMSEA                                    0.057
##      90 Percent confidence interval - lower    0.000
##      90 Percent confidence interval - upper    0.107
##      P-value RMSEA <= 0.05                    0.352
##
## Standardized Root Mean Square Residual:
##
##      SRMR                                    0.033
##
## Parameter Estimates:
##
##      Standard errors                          Bootstrap
##      Number of requested bootstrap draws      1000
##      Number of successful bootstrap draws      1000
##
## Regressions:
##      Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## stress ~
##   coa      (a)   0.451   0.072   6.219   0.000   0.451   0.331
## emotion ~
##   coa      (e)   0.116   0.054   2.130   0.033   0.116   0.115
## negaff ~
##   stress   (x)   0.243   0.092   2.633   0.008   0.243   0.172
##   emotion  (y)   0.582   0.109   5.350   0.000   0.582   0.304
## peer ~
##   negaff   (z)   0.137   0.029   4.661   0.000   0.137   0.245
##   coa      (i)   0.185   0.053   3.475   0.001   0.185   0.172

```

```
##      age      (j)    0.138    0.016    8.418    0.000    0.138    0.371
##      negaff ~
##      age      (k)    0.119    0.031    3.879    0.000    0.119    0.179
##
## Covariances:
##              Estimate Std.Err  z-value  P(>|z|)   Std.lv  Std.all
##      .stress ~~
##      .emotion    0.112    0.019    6.033    0.000    0.112    0.350
##      coa ~~
##      age      -0.055    0.041   -1.335    0.182   -0.055   -0.076
##
## Variances:
##              Estimate Std.Err  z-value  P(>|z|)   Std.lv  Std.all
##      .stress    0.412    0.041   10.113    0.000    0.412    0.891
##      .emotion    0.249    0.017   14.561    0.000    0.249    0.987
##      .negaff     0.749    0.066   11.391    0.000    0.749    0.810
##      .peer       0.216    0.028    7.773    0.000    0.216    0.745
##      coa         0.249    0.002  140.783    0.000    0.249    1.000
##      age        2.095    0.131   15.939    0.000    2.095    1.000
```

```
semPaths(sem3v, "mod", "par", col=rainbow(6), style="lisrel", layout = "tree2", curve=1.5, curvePivot = TRUE, rotation
legend("topright", legend=c("Modelo de trayectoria: Reajustado"), col="blue", cex=1.1)
```

