



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

INSTITUTO DE INVESTIGACIONES EN MATEMÁTICAS
APLICADAS Y EN SISTEMAS

ESPECIALIZACIÓN EN ESTADÍSTICA APLICADA

Modelos de Ecuaciones Estructurales

Adicción juvenil y padres alcohólicos

Jesus Alberto Urrutia Camacho (urcajeal@gmail.com)

Ciudad de México

11 de junio de 2021


El Proyecto para el Desarrollo de la familia y el adolescente (*The Adolescent and Family Development Project*, en los Estados Unidos) diseñó una investigación que tiene por objetivo “evaluar la asociación entre el alcoholismo de los padres y el uso de sustancias en adolescentes y psicopatologías” (Zamora, 2021). Para tal propósito, se levantó una muestra aleatoria integrada por 316 adolescentes. Además, la muestra es compuesta íntegramente por variables medidas, por lo que se realiza un Análisis de Trayectoria (o *Path Analysis*), lo cuál requiere que haya teorías y conceptos de área que respalden la investigación.

Específicamente, se parte de la siguiente teorización. Los padres alcohólicos (*coa*) inciden en vidas con efectos estresantes (*stress*) para las y los hijos, lo que aumenta la percepción de depresión y ansiedad en los adolescentes (*negaff*). Además, se considera que las familias alcohólicas provoca en los jóvenes falta de control emocional (*emotion*), lo que incrementa depresión y ansiedad (*negaff*) en estos últimos. Entonces, se podría argüir que eventos estresantes (*stress*) tiene una relación no direccional con falta de control emocional (*emotion*). En complemento a lo anterior, los resultados negativos, como ansiedad y depresión, generan tasas altas de convivencia con compañeros que consumen drogas (*peer*), lo que podría generar adicciones. Finalmente, se considera que el estrés (*stress*) y la dificultad emocional (*emotion*) son predichas por la edad (*age*) y el sexo (*gen*).

A continuación se muestra una tabla con el *nombre de variables*, sus *siglas*, a manera de codificación, y las variables que representan.

Dado que se cuenta con la base de datos se procede a hacer estadística descriptiva. Todas las variables son numéricas, pero *coa* y *gen* son variables dicotómicas, donde $P(X|x_{coa} = 0 : \text{Padresnoalcoholicos})$, y $P(X|x_{gen} = 0 : \text{Mujer})$, respectivamente. Además, las variables, *Stress*, *emotion*, *negaff* y *peer* son variables continuas, que parecen ser tasas o índices, ya que tienen valores positivos y menores de 6. Cabe destacar que no se cuenta con un diccionario de datos.

A continuación se muestran dos correlogramas. Cabe señalar que no hay ninguna correlación significativa. El primer correlograma integra a las correlaciones biserial, tetracórica y de pearson. Mientras que el segundo solamente usa la última correlación. Se evidencia, que las correlaciones para variables dicotómicas aumentaron (es decir, se intensificó su color).



1. Diagramar modelo

```

CorMid <- '
1.0
-0.09456621 1.0
0.01400000 0.12159467 1.0
0.41430068 -0.01973430 -0.01121133 1.0
0.14398422 -0.08074436 -0.04854675 0.3664796 1.0
0.10279496 0.15121667 -0.12520711 0.2807905 0.35387788 1.0
0.20542024 0.39572236 -0.10289694 0.2402493 0.13368237 0.3145978 1.0
'

# corCuaad <- matrix(data = c(c(1, -0.09456621, 0.014, 0.41430068, 0.14398422, 0.10279496, 0.20542024),
#                               c(-0.09456621, 1, 0.12159467, -0.01973430, -0.08074436, 0.15121667, 0.39572236 ),
#                               c(0.014, 0.12159467, 1, -0.01121133, -0.04854675, -0.12520711, -0.10289694),
#                               c(0.41430068, -0.01973430 , -0.01121133, 1, 0.3664796, 0.2807905, 0.2402493),
#                               c(0.14398422, -0.08074436, -0.04854675, 0.3664796, 1, 0.35387788, 0.13368237 ),
#                               c(0.10279496, 0.15121667, -0.12520711, 0.2807905, 0.35387788, 1, 0.3145978),
#                               c(0.20542024, 0.39572236, -0.10289694, 0.2402493 , 0.13368237, 0.3145978, 1)
#                               ),7,7)

comp.cor1 <- getCov(CorMid, sds = NULL, names = c("coa", "age", "gen", "stress", "emotion", "negaff", "peer"))

#Modelo teórico

mod1 <- '
stress ~ a*coa + b*gen + c*age
emotion ~ e*coa + f*gen + g*age
negaff ~ x*stress + y*emotion
peer ~ z*negaff

emotion ~~ stress
coa ~~ gen
gen ~~ age
coa ~~ age

#Efectos indirectos

NegStresCoa := x*a
NegStresGen := x*b
NegStresAge := x*c
NegEmoCoa := y*e
NegEmoGen := y*f
NegEmoAge := y*g
PeNegStresCoa := z*x*a
PeNegEmoCoa := z*y*e

#Efectos Totales
T1 := a + x*a + z*x*a
T2 := a + y*e + z*y*e
'

n <- length(bd$coa)
sem1 <- sem(mod1, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")
sem2 <- sem(mod1, data = bd, sample.cov = personc, sample.nobs = n, se="bootstrap")

```

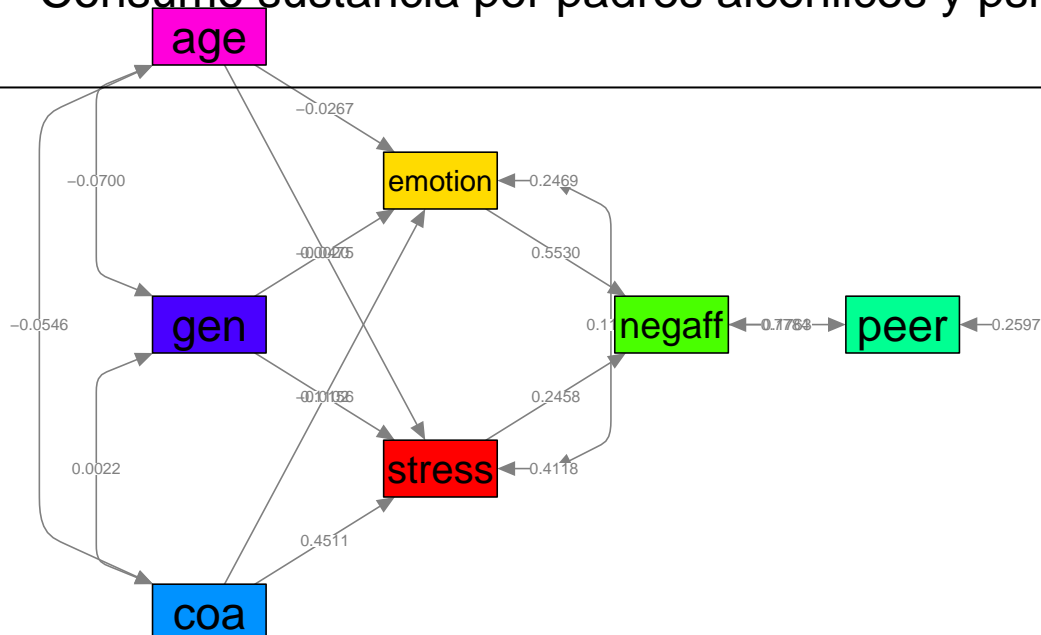
```
summary(sem1, fit.measures = TRUE, standardized=T)
```

```
## lavaan 0.6-8 ended normally after 31 iterations
##
## Estimator ML
## Optimization method NLMINB
## Number of model parameters 20
##
## Number of observations 316
##
## Model Test User Model:
##
## Test statistic 81.173
## Degrees of freedom 8
## P-value (Chi-square) 0.000
##
## Model Test Baseline Model:
##
## Test statistic 255.823
## Degrees of freedom 21
## P-value 0.000
##
## User Model versus Baseline Model:
##
## Comparative Fit Index (CFI) 0.688
## Tucker-Lewis Index (TLI) 0.182
##
## Loglikelihood and Information Criteria:
##
## Loglikelihood user model (H0) -2179.133
## Loglikelihood unrestricted model (H1) -2138.547
##
## Akaike (AIC) 4398.267
## Bayesian (BIC) 4473.382
## Sample-size adjusted Bayesian (BIC) 4409.947
##
## Root Mean Square Error of Approximation:
##
## RMSEA 0.170
## 90 Percent confidence interval - lower 0.138
## 90 Percent confidence interval - upper 0.205
## P-value RMSEA <= 0.05 0.000
##
## Standardized Root Mean Square Residual:
##
## SRMR 0.095
##
## Parameter Estimates:
##
## Standard errors Bootstrap
## Number of requested bootstrap draws 1000
## Number of successful bootstrap draws 1000
##
```

```
## Regressions:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## stress ~
##   coa      (a)    0.451   0.075   5.999   0.000   0.451   0.331
##   gen      (b)   -0.016   0.073  -0.214   0.831  -0.016  -0.011
##   age      (c)    0.002   0.026   0.077   0.939   0.002   0.004
## emotion ~
##   coa      (e)    0.110   0.057   1.946   0.052   0.110   0.110
##   gen      (f)   -0.048   0.057  -0.833   0.405  -0.048  -0.047
##   age      (g)   -0.027   0.022  -1.209   0.227  -0.027  -0.077
## negaff ~
##   stress    (x)    0.246   0.094   2.628   0.009   0.246   0.175
##   emotion    (y)    0.553   0.115   4.819   0.000   0.553   0.290
## peer ~
##   negaff    (z)    0.176   0.032   5.550   0.000   0.176   0.315
##
## Covariances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .stress ~~
## .emotion      0.112   0.018   6.187   0.000   0.112   0.352
## coa ~~
##   gen      0.002   0.014   0.157   0.875   0.002   0.009
## gen ~~
##   age     -0.070   0.040  -1.763   0.078  -0.070  -0.097
## coa ~~
##   age     -0.055   0.041  -1.347   0.178  -0.055  -0.076
##
## Variances:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .stress      0.412   0.040  10.369   0.000   0.412   0.890
## .emotion      0.247   0.017  14.537   0.000   0.247   0.979
## .negaff       0.778   0.071  11.002   0.000   0.778   0.848
## .peer         0.260   0.032   8.001   0.000   0.260   0.901
## coa           0.249   0.002 141.501   0.000   0.249   1.000
## gen           0.249   0.002 106.199   0.000   0.249   1.000
## age          2.095   0.124  16.922   0.000   2.095   1.000
##
## Defined Parameters:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## NegStresCoa    0.111   0.046   2.430   0.015   0.111   0.058
## NegStresGen   -0.004   0.019  -0.201   0.841  -0.004  -0.002
## NegStresAge    0.000   0.007   0.071   0.943   0.000   0.001
## NegEmoCoa     0.061   0.034   1.785   0.074   0.061   0.032
## NegEmoGen     -0.026   0.033  -0.801   0.423  -0.026  -0.014
## NegEmoAge     -0.015   0.012  -1.255   0.210  -0.015  -0.022
## PeNegStresCoa  0.020   0.009   2.078   0.038   0.020   0.018
## PeNegEmoCoa   0.011   0.007   1.633   0.103   0.011   0.010
## T1            0.582   0.106   5.463   0.000   0.582   0.407
## T2            0.523   0.094   5.543   0.000   0.523   0.373
##
#
# summary(modelo, fit.measures = TRUE, standardized=T)
# #resumes <- summary(modelo, fit.measures = TRUE, standardized=T)
# fitmeasures(modelo)
```

```
semPaths(sem1, "mod", "par", col=rainbow(7), style="lisrel", layout = "tree2", curve=1.5, curvePivot = TRUE,
legend("topleft", legend=c("Consumo sustancia por padres alcohólicos y psicopatologías"), col="blue", cex=
```

Consumo sustancia por padres alcohólicos y psicopatologías



2. Escribirlo matricialmente

$$Y_{stres} = 0Y_{stres} + 0Y_{emo} + 0Y_{neg} + 0Y_{peer} + \gamma_{1,1}X_{coa} + \gamma_{1,2}X_{gen} + \gamma_{1,3}X_{age} + \varsigma_1$$

$$Y_{emo} = 0Y_{stres} + 0Y_{emo} + 0Y_{neg} + 0Y_{peer} + \gamma_{2,1}X_{coa} + \gamma_{2,2}X_{gen} + \gamma_{2,3}X_{age} + \varsigma_2$$

$$Y_{neg} = \beta_{1,1}Y_{stres} + \beta_{1,2}Y_{emo} + 0Y_{neg} + 0Y_{peer} + 0X_{coa} + 0X_{gen} + 0X_{age} + \varsigma_3$$

$$Y_{emo} = 0Y_{stres} + 0Y_{emo} + \beta_{2,1}Y_{neg} + 0Y_{peer} + 0X_{coa} + 0X_{gen} + 0X_{age} + \varsigma_4$$

$$\begin{bmatrix} Y_{stres} \\ Y_{emo} \\ Y_{neg} \\ Y_{peer} \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ \beta_{1,1} & \beta_{1,2} & 0 & 0 \\ 0 & 0 & \beta_{2,1} & 0 \end{bmatrix} \begin{bmatrix} Y_{stres} \\ Y_{emo} \\ Y_{neg} \\ Y_{peer} \end{bmatrix} + \begin{bmatrix} \gamma_{1,1} & \gamma_{1,2} & \gamma_{1,3} \\ \gamma_{2,1} & \gamma_{2,2} & \gamma_{2,3} \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} X_{coa} \\ X_{gen} \\ X_{age} \end{bmatrix} + \begin{bmatrix} \varsigma_1 \\ \varsigma_2 \\ \varsigma_3 \\ \varsigma_4 \end{bmatrix}$$

3. Escribir matrices involucradas en modelo

Además, respectivamente, cada matriz presentada con anterioridad puede se expresada como: $Y = BY + \Gamma x + \zeta$

$$\Psi = \begin{bmatrix} \psi_{1,1} & 0 & 0 & 0 \\ \psi_{2,1} & \psi_{2,2} & 0 & 0 \\ 0 & 0 & \psi_{3,1} & 0 \\ 0 & 0 & 0 & \psi_{4,1} \end{bmatrix} \quad \Phi = \begin{bmatrix} \phi_{1,1} & 0 & 0 \\ \phi_{2,1} & \phi_{2,2} & 0 \\ \phi_{3,1} & \phi_{3,2} & \phi_{3,3} \end{bmatrix}$$

Cabe destacar que Ψ representa la matriz de correlación entre variables endógenas (Y_i). Mientras que la matriz de Φ presenta a la correlación entre variables exógenas (X_i).

4. Ajuste del modelo

La estimación del modelo emplea el método bootstrap, como alternativa a las restricciones del supuesto de normalidad por el método delta. Lo anterior requiere que la muestra esté disponible para realizar el remuestreo (Hallquist, 2019).

Además, se emplean la paquetería *lavaan* como principal instrumento de ajuste computaciones, y se usa la información de la matriz de correlación de Pearson, biserial y tetracórica, según corresponda el tipo de variable. Se tienen 20 grados de libertad, lo que corresponde a las parte de información. A continuación se muestra el código empleado.

```
# CorMid
# comp.cor1 <- getCov(CorMid, sds = NULL, names = c("coa", "age", "gen", "stress", "emotion", "negaff",
# mod1
# sem1 <- sem(mod1, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")

summary(sem1, fit.measures = TRUE, standardized=T)

## lavaan 0.6-8 ended normally after 31 iterations
##
##   Estimator                      ML
##   Optimization method          NLMINB
##   Number of model parameters    20
##
##   Number of observations        316
##
## Model Test User Model:
##
##   Test statistic                  81.173
##   Degrees of freedom              8
##   P-value (Chi-square)           0.000
##
## Model Test Baseline Model:
##
##   Test statistic                  255.823
##   Degrees of freedom              21
##   P-value                        0.000
##
## User Model versus Baseline Model:
##
##   Comparative Fit Index (CFI)    0.688
##   Tucker-Lewis Index (TLI)      0.182
##
```

```
## Loglikelihood and Information Criteria:
##
##   Loglikelihood user model (H0)          -2179.133
##   Loglikelihood unrestricted model (H1)   -2138.547
##
##   Akaike (AIC)                          4398.267
##   Bayesian (BIC)                        4473.382
##   Sample-size adjusted Bayesian (BIC)    4409.947
##
## Root Mean Square Error of Approximation:
##
##   RMSEA                                0.170
##   90 Percent confidence interval - lower  0.138
##   90 Percent confidence interval - upper  0.205
##   P-value RMSEA <= 0.05                 0.000
##
## Standardized Root Mean Square Residual:
##
##   SRMR                                0.095
##
## Parameter Estimates:
##
##   Standard errors                      Bootstrap
##   Number of requested bootstrap draws    1000
##   Number of successful bootstrap draws    1000
##
## Regressions:
##
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
## stress ~
##   coa      (a)    0.451    0.075    5.999    0.000    0.451    0.331
##   gen      (b)   -0.016    0.073   -0.214    0.831   -0.016   -0.011
##   age      (c)    0.002    0.026    0.077    0.939    0.002    0.004
## emotion ~
##   coa      (e)    0.110    0.057    1.946    0.052    0.110    0.110
##   gen      (f)   -0.048    0.057   -0.833    0.405   -0.048   -0.047
##   age      (g)   -0.027    0.022   -1.209    0.227   -0.027   -0.077
## negaff ~
##   stress   (x)    0.246    0.094    2.628    0.009    0.246    0.175
##   emotion  (y)    0.553    0.115    4.819    0.000    0.553    0.290
## peer ~
##   negaff   (z)    0.176    0.032    5.550    0.000    0.176    0.315
##
## Covariances:
##
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
## .stress ~~
##   .emotion      0.112    0.018    6.187    0.000    0.112    0.352
## coa ~~
##   gen          0.002    0.014    0.157    0.875    0.002    0.009
## gen ~~
##   age        -0.070    0.040   -1.763    0.078   -0.070   -0.097
## coa ~~
##   age       -0.055    0.041   -1.347    0.178   -0.055   -0.076
##
## Variances:
```



```
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .stress          0.412   0.040  10.369   0.000   0.412   0.890
## .emotion          0.247   0.017  14.537   0.000   0.247   0.979
## .negaff           0.778   0.071  11.002   0.000   0.778   0.848
## .peer             0.260   0.032   8.001   0.000   0.260   0.901
## coa                0.249   0.002 141.501   0.000   0.249   1.000
## gen                0.249   0.002 106.199   0.000   0.249   1.000
## age               2.095   0.124  16.922   0.000   2.095   1.000
##
## Defined Parameters:
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## NegStresCoa        0.111   0.046   2.430   0.015   0.111   0.058
## NegStresGen       -0.004   0.019  -0.201   0.841  -0.004  -0.002
## NegStresAge        0.000   0.007   0.071   0.943   0.000   0.001
## NegEmoCoa          0.061   0.034   1.785   0.074   0.061   0.032
## NegEmoGen         -0.026   0.033  -0.801   0.423  -0.026  -0.014
## NegEmoAge         -0.015   0.012  -1.255   0.210  -0.015  -0.022
## PeNegStresCoa      0.020   0.009   2.078   0.038   0.020   0.018
## PeNegEmoCoa        0.011   0.007   1.633   0.103   0.011   0.010
## T1                  0.582   0.106   5.463   0.000   0.582   0.407
## T2                  0.523   0.094   5.543   0.000   0.523   0.373
```

```
#resumen <- summary(modelo, fit.measures = TRUE, standardized=T)
fitmeasures(sem1)
```

```
##           npar           fmin           chisq           df
##           20.000           0.128           81.173           8.000
##           pvalue      baseline.chisq      baseline.df      baseline.pvalue
##           0.000           255.823           21.000           0.000
##           cfi           tli           nnfi           rfi
##           0.688           0.182           0.182           0.167
##           nfi           pnfi           ifi           rni
##           0.683           0.260           0.705           0.688
##           logl      unrestricted.logl           aic           bic
##           -2179.133      -2138.547           4398.267           4473.382
##           ntotal           bic2           rmsea      rmsea.ci.lower
##           316.000           4409.947           0.170           0.138
##           rmsea.ci.upper      rmsea.pvalue           rmr           rmr_nomean
##           0.205           0.000           0.077           0.077
##           srmr           srmr_bentler      srmr_bentler_nomean           crmr
##           0.095           0.095           0.095           0.109
##           crmr_nomean      srmr_mplus      srmr_mplus_nomean           cn_05
##           0.109           0.095           0.095           61.369
##           cn_01           gfi           agfi           pgfi
##           79.210           0.940           0.790           0.269
##           mfi           ecvi
##           0.891           0.383
```

La estimación de los parámetros se muestra a continuación:

5. Verifique lo adecuado del ajuste

A fin de verificar el ajuste del modelo, se deben considerar los índices de bondad de ajuste (GoF, por sus siglas en Inglés).

La prueba de la χ^2 rechaza la hipótesis nula, donde $H_o : Modelo\acute{S}iAjusta$, es decir que el modelo no ajusta a los datos. Debido a que el Pvalor es mucho menor que la significancia. Sin embargo, el modelo basal es mucho peor que el propuesto.

User Model:

Test statistic 81.173 Degrees of freedom 8 P-value (Chi-square) 0.000

Model Test Baseline Model:

Test statistic 255.823 Degrees of freedom 21 P-value 0.000

Cuadro 1: Índices de ajuste del modelo

CFI	TLI	RMSEA	Pvalue	RMSEA	SRMR
0.688	0.182	0.17	0.0		0.095

- CFI: Es el **Comparative Fit Index**, en que este modelo tiene un valor muy pequeño. Por lo que se puede sostener que el modelo es muy malo. Además, para valores "mayor 0.97 es indicativo de un buen ajuste en relación con el modelo de independencia"(Zamora, 2021).
- NNFI ,también conocido como TLI, es decir, "índice de ajuste no normalizado (NNFI), también conocido como el índice de Tucker-Lewis (TLI)". Este modelo tiene un valor muy pequeño, lo que indica que el modelo es malo. Ya que "valores superiores a 0.95 pueden interpretarse como un ajuste aceptable"(Zamora, 2021).
- RMSEA, significa error cuadrático medio de aproximación de la raíz. Donde valores mayores a 0.1, implican valores de ajuste medriocres, por lo que este modelo no es bueno.
- Pvalor RMSEA, implica que el valor puntual de RMSAE sea contenido por un intervalor de confianza del 95
- SRMR, o índice de la raíz del cuadrado medio del residuo estandarizado, "valores de SRMR menores a 0.05 evidencian un buen ajuste y que menores a 0.10 pueden interpretarse como un ajuste aceptable"(Zamora, 2021). Por lo que se puede afirmar que este modelo tiene un ajuste aceptable.

Por lo anterior es posible afirmar que el modelo, en general, no ajusta. Es decir, los datos no respaldan la teoría propuesta. Entonces, se sugiere modificar las relaciones entre variables, siempre y cuando esté mediada por conocimiento de área experta.

Dado lo anterior se propone reestructurar el modelo en función de conocimiento experto. Donde las únicas variables que medien el modelo sean el hecho que los padres sean alcoholicos (*coa*), su efecto sobre eventos estresantes (*stres*) y sobre falta de control de emociones (*emotion*) ambas en los adolescentes. Y la incidencia de las anteriores sobre ansiedad y depresión (*negaff*), y su vez sobre el consumo de sustancia (*peer*).

Entonces, la graficación del modelo quedaría como sigue. Respecto a la forma de estimación del modelo sigue los mismo procesos que el anterior modelo. Y a continuación se muestran los índices de bondad de ajute.

```
mod2v <- '
stress ~ a*coa
emotion ~ e*coa
negaff ~ x*stress + y*emotion
peer ~ z*negaff

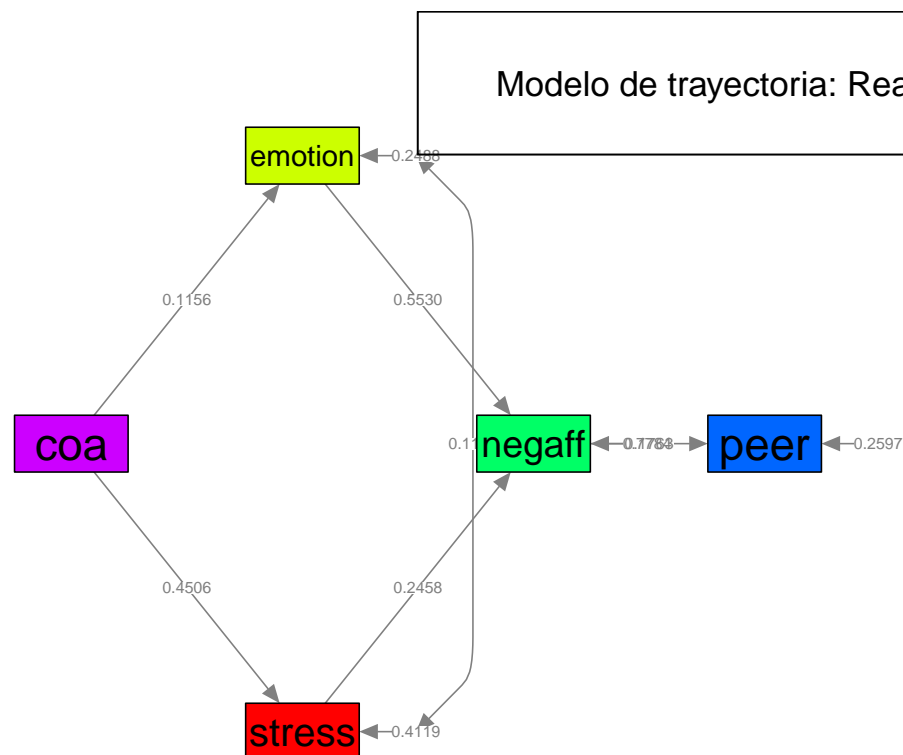
emotion ~~ stress
'
```

```
sem3v <- sem(mod2v, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")
summary(sem3v, fit.measures = TRUE, standardized=T)
```

```
## lavaan 0.6-8 ended normally after 20 iterations
##
##      Estimator                      ML
##      Optimization method          NLMINB
##      Number of model parameters      10
##
##      Number of observations          316
##
## Model Test User Model:
##
##      Test statistic                  12.267
##      Degrees of freedom                4
##      P-value (Chi-square)             0.015
##
## Model Test Baseline Model:
##
##      Test statistic                  179.377
##      Degrees of freedom              10
##      P-value                         0.000
##
## User Model versus Baseline Model:
##
##      Comparative Fit Index (CFI)      0.951
##      Tucker-Lewis Index (TLI)        0.878
##
## Loglikelihood and Information Criteria:
##
##      Loglikelihood user model (H0)    -1160.310
##      Loglikelihood unrestricted model (H1) -1154.176
##
##      Akaike (AIC)                    2340.620
##      Bayesian (BIC)                   2378.177
##      Sample-size adjusted Bayesian (BIC) 2346.460
##
## Root Mean Square Error of Approximation:
##
##      RMSEA                           0.081
##      90 Percent confidence interval - lower 0.032
##      90 Percent confidence interval - upper 0.134
##      P-value RMSEA <= 0.05             0.131
##
## Standardized Root Mean Square Residual:
##
##      SRMR                             0.053
##
## Parameter Estimates:
##
##      Standard errors                  Bootstrap
##      Number of requested bootstrap draws 1000
##      Number of successful bootstrap draws 1000
##
```

```
## Regressions:
##               Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## stress ~
##   coa      (a)   0.451   0.070   6.432   0.000   0.451   0.331
## emotion ~
##   coa      (e)   0.116   0.055   2.084   0.037   0.116   0.115
## negaff ~
##   stress   (x)   0.246   0.093   2.644   0.008   0.246   0.175
##   emotion  (y)   0.553   0.116   4.747   0.000   0.553   0.290
## peer ~
##   negaff   (z)   0.176   0.033   5.313   0.000   0.176   0.315
##
## Covariances:
##               Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .stress ~~
##   .emotion      0.112   0.018   6.158   0.000   0.112   0.350
##
## Variances:
##               Estimate Std.Err z-value P(>|z|) Std.lv Std.all
##   .stress      0.412   0.040  10.266   0.000   0.412   0.891
##   .emotion      0.249   0.017  14.348   0.000   0.249   0.987
##   .negaff       0.778   0.072  10.842   0.000   0.778   0.848
##   .peer         0.260   0.032   8.085   0.000   0.260   0.901
```

```
semPaths(sem3v, "mod", "par", col=rainbow(5), style="lisrel", layout = "tree2", curve=1.5, curvePivot = TR
legend("topright", legend=c("Modelo de trayectoria: Reajustado"), col="blue", cex=1.1)
```



6. Interpretar efectos directos, indirectos, totales y concluir

Si se parte del segundo modelo teórico, es posible interpretar los efectos, como se menciona a continuación.