

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

INSTITUTO DE INVESTIGACIONES EN MATEMÁTICAS  
APLICADAS Y EN SISTEMAS

ESPECIALIZACIÓN EN ESTADÍSTICA APLICADA

Modelos de Ecuaciones Estructurales

Adicción juvenil y padres alcohólicos

Jesus Alberto Urrutia Camacho (urcajeal@gmail.com)

Ciudad de México

11 de junio de 2021

El Proyecto para el Desarrollo de la familia y el adolescente ( *The Adolescent and Family Development Project*, en los Estados Unidos) diseñó una investigación que tiene por objetivo “evaluar la asociación entre el alcoholismo de los padres y el uso de sustancias en adolescentes y psicopatologías” (Zamora, 2021). Para tal propósito, se levantó una muestra aleatoria integrada por 316 adolescentes. Además, la muestra es compuesta íntegramente por variables medidas, por lo que se realiza un Análisis de Trayectoria (o *Path Analysis*), lo cuál requiere que haya teorías y conceptos de área que respalden la investigación.

Específicamente, se parte de la siguiente teorización. Los padres alcohólicos ( *coa* ) inciden en vidas con efectos estresantes ( *stress* ) para las y los hijos, lo que aumenta la percepción de depresión y ansiedad en los adolescentes ( *negaff* ). Además, se considera que las familias alcohólicas provoca en los jóvenes falta de control emocional ( *emotion* ), lo que incrementa depresión y ansiedad ( *negaff* ) en estos últimos. Entonces, se podría argüir que eventos estresantes ( *stress* ) tiene una relación no direccional con falta de control emocional ( *emotion* ). En complemento a lo anterior, los resultados negativos, como ansiedad y depresión, generan tasas altas de convivencia con compañeros que consumen drogas ( *peer* ), lo que podría generar adicciones. Finalmente, se considera que el estrés ( *stress* ) y la dificultad emocional ( *emotion* ) son predichas por la edad ( *age* ) y el sexo ( *gen* ).

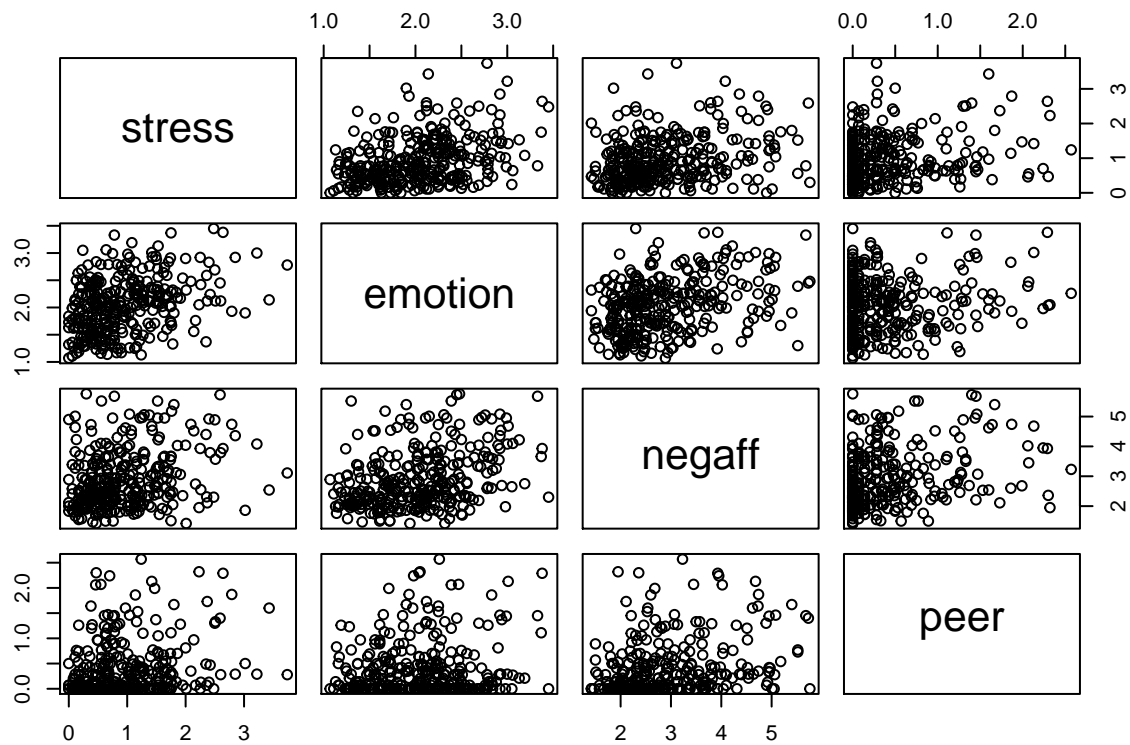
A continuación se muestra una tabla con el *nombre de variables*, sus *siglas*, a manera de codificación, y las variables que representan.

Dado que se cuenta con la base de datos se procede a hacer estadística descriptiva. Todas las variables son numéricas, pero *coa* y *gen* son variables dicotómicas, donde  $P(X|x_{coa} = 0 : \text{Padresnoalcoholicos})$ , y  $P(X|x_{gen} = 0 : \text{Mujer})$ , respectivamente. Además, las variables, *Stress*, *emotion*, *negaff* y *peer* son variables continuas, que parecen ser tasas o índices, ya que tienen valores positivos y menores de 6. Cabe destacar que no se cuenta con un diccionario de datos.

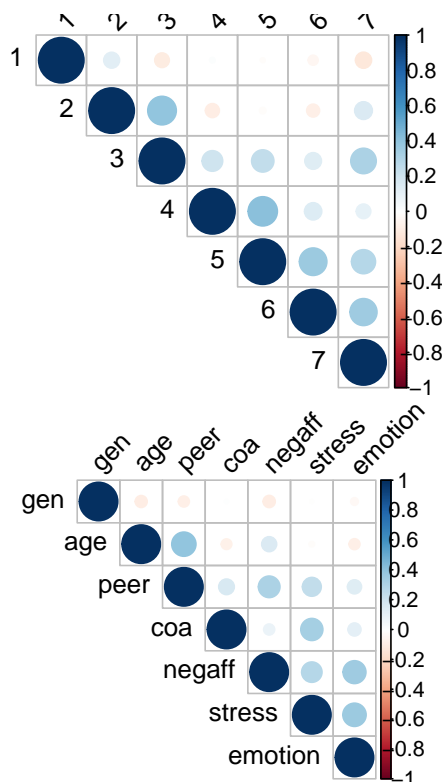
```
## tibble[,7] [316 x 7] (S3: tbl_df/tbl/data.frame)
## $ coa      : num [1:316] 1 1 1 1 1 1 1 1 1 1 ...
## $ age      : num [1:316] 14 12 14 15 12 13 13 10 11 11 ...
## $ gen      : num [1:316] 0 0 1 1 1 0 0 0 1 0 ...
## $ stress   : num [1:316] 2.35 0.55 2.37 1.14 1.37 0.55 0.53 1.53 1.36 1.34 ...
## $ emotion  : num [1:316] 1.37 1.46 2.12 2.83 2.11 1.57 1.38 3.13 1.71 2.48 ...
## $ negaff   : num [1:316] 4.4 2.34 2.11 2.6 2.04 2.93 3.15 4.22 2.85 2.33 ...
## $ peer     : num [1:316] 0.49 0 1.73 1.86 0.36 0.21 0 0.21 0 0.21 ...

##      coa      age      gen      stress
## Min.   :0.0000   Min.   :10.00   Min.   :0.000   Min.   :0.0000
## 1st Qu.:0.0000   1st Qu.:12.00   1st Qu.:0.000   1st Qu.:0.4325
## Median :1.0000   Median :13.00   Median :1.000   Median :0.7800
## Mean   :0.5253   Mean   :12.72   Mean   :0.538   Mean   :0.9407
## 3rd Qu.:1.0000   3rd Qu.:14.00   3rd Qu.:1.000   3rd Qu.:1.3100
## Max.   :1.0000   Max.   :16.00   Max.   :1.000   Max.   :3.7400

##      emotion  negaff      peer
## Min.   :1.070   Min.   :1.420   Min.   :0.0000
## 1st Qu.:1.627   1st Qu.:2.185   1st Qu.:0.0000
## Median :2.040   Median :2.605   Median :0.1400
## Mean   :2.034   Mean   :2.883   Mean   :0.3903
## 3rd Qu.:2.370   3rd Qu.:3.413   3rd Qu.:0.5075
## Max.   :3.450   Max.   :5.760   Max.   :2.5700
```



A continuación se muestran dos correlogramas. Cabe señalar que no hay ninguna correlación significativa. El primer correlograma integra a las correlaciones biserial, tetracórica y de pearson. Mientras que el segundo solamente usa la última correlación. Se evidencia, que las correlaciones para variables dicotómicas aumentaron (es decir, se intensificó su color).



## 1. Diagramar modelo

```
CorMid <- '
1.0
-0.09456621 1.0
0.01400000 0.12159467 1.0
0.41430068 -0.01973430 -0.01121133 1.0
0.14398422 -0.08074436 -0.04854675 0.3664796 1.0
0.10279496 0.15121667 -0.12520711 0.2807905 0.35387788 1.0
0.20542024 0.39572236 -0.10289694 0.2402493 0.13368237 0.3145978 1.0
'

# corCuad <- matrix(data = c(c(1, -0.09456621, 0.014, 0.41430068, 0.14398422, 0.10279496, 0.20542024),
#                               c(-0.09456621, 1, 0.12159467, -0.01973430, -0.08074436, 0.15121667, 0.39572236 ),
#                               c(0.014, 0.12159467, 1, -0.01121133, -0.04854675, -0.12520711, -0.10289694),
#                               c(0.41430068, -0.01973430, -0.01121133, 1, 0.3664796, 0.2807905, 0.2402493),
#                               c(0.14398422, -0.08074436, -0.04854675, 0.3664796, 1, 0.35387788, 0.13368237 ),
#                               c(0.10279496, 0.15121667, -0.12520711, 0.2807905, 0.35387788, 1, 0.3145978),
#                               c(0.20542024, 0.39572236, -0.10289694, 0.2402493, 0.13368237, 0.3145978, 1)
#                               ),7,7)

comp.cor1 <- getCov(CorMid, sds = NULL, names = c("coa", "age", "gen", "stress", "emotion", "negaff", "peer"))

#Modelo teórico

mod1 <- '
stress ~ a*coa + b*gen + c*age
emotion ~ e*coa + f*gen + g*age
```

```

negaff ~ x*stress + y*emotion
peer ~ z*negaff

emotion ~~ stress
coa ~~ gen
gen ~~ age
coa ~~ age

#Efectos indirectos

NegStresCoa := x*a
NegStresGen := x*b
NegStresAge := x*c
NegEmoCoa := y*e
NegEmoGen := y*f
NegEmoAge := y*g
PeNegStresCoa := z*x*a
PeNegEmoCoa := z*y*e

#Efectos Totales
T1 := a + x*a + z*x*a
T2 := a + y*e + z*y*e
'

n <- length(bd$coa)
sem1 <- sem(mod1, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")
sem2 <- sem(mod1, data = bd, sample.cov = personc, sample.nobs = n, se="bootstrap")

summary(sem1, fit.measures = TRUE, standardized=T)

## lavaan 0.6-8 ended normally after 31 iterations
##
##      Estimator                      ML
##      Optimization method          NLMINB
##      Number of model parameters      20
##
##      Number of observations          316
##
## Model Test User Model:
##
##      Test statistic                  81.173
##      Degrees of freedom              8
##      P-value (Chi-square)            0.000
##
## Model Test Baseline Model:
##
##      Test statistic                  255.823
##      Degrees of freedom              21
##      P-value                          0.000
##
## User Model versus Baseline Model:
##
##      Comparative Fit Index (CFI)      0.688
##      Tucker-Lewis Index (TLI)        0.182

```

```
##
## Loglikelihood and Information Criteria:
##
##   Loglikelihood user model (H0)          -2179.133
##   Loglikelihood unrestricted model (H1)   -2138.547
##
##   Akaike (AIC)                          4398.267
##   Bayesian (BIC)                        4473.382
##   Sample-size adjusted Bayesian (BIC)    4409.947
##
## Root Mean Square Error of Approximation:
##
##   RMSEA                                0.170
##   90 Percent confidence interval - lower  0.138
##   90 Percent confidence interval - upper  0.205
##   P-value RMSEA <= 0.05                 0.000
##
## Standardized Root Mean Square Residual:
##
##   SRMR                                0.095
##
## Parameter Estimates:
##
##   Standard errors                      Bootstrap
##   Number of requested bootstrap draws    1000
##   Number of successful bootstrap draws    1000
##
## Regressions:
##
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
## stress ~
##   coa      (a)    0.451    0.070    6.436    0.000    0.451    0.331
##   gen      (b)   -0.016    0.072   -0.217    0.828   -0.016   -0.011
##   age      (c)    0.002    0.026    0.074    0.941    0.002    0.004
## emotion ~
##   coa      (e)    0.110    0.055    2.011    0.044    0.110    0.110
##   gen      (f)   -0.048    0.056   -0.845    0.398   -0.048   -0.047
##   age      (g)   -0.027    0.022   -1.243    0.214   -0.027   -0.077
## negaff ~
##   stress   (x)    0.246    0.094    2.609    0.009    0.246    0.175
##   emotion  (y)    0.553    0.118    4.675    0.000    0.553    0.290
## peer ~
##   negaff   (z)    0.176    0.033    5.339    0.000    0.176    0.315
##
## Covariances:
##
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
## .stress ~~
##   .emotion      0.112    0.018    6.116    0.000    0.112    0.352
## coa ~~
##   gen          0.002    0.014    0.161    0.872    0.002    0.009
## gen ~~
##   age        -0.070    0.042   -1.683    0.092   -0.070   -0.097
## coa ~~
##   age       -0.055    0.041   -1.333    0.183   -0.055   -0.076
##
```

## Variances:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
## .stress	0.412	0.041	10.154	0.000	0.412	0.890
## .emotion	0.247	0.018	13.841	0.000	0.247	0.979
## .negaff	0.778	0.067	11.622	0.000	0.778	0.848
## .peer	0.260	0.033	7.896	0.000	0.260	0.901
## coa	0.249	0.002	129.447	0.000	0.249	1.000
## gen	0.249	0.003	96.806	0.000	0.249	1.000
## age	2.095	0.132	15.859	0.000	2.095	1.000

##

## Defined Parameters:

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
## NegStresCoa	0.111	0.047	2.378	0.017	0.111	0.058
## NegStresGen	-0.004	0.019	-0.198	0.843	-0.004	-0.002
## NegStresAge	0.000	0.007	0.067	0.946	0.000	0.001
## NegEmoCoa	0.061	0.033	1.821	0.069	0.061	0.032
## NegEmoGen	-0.026	0.032	-0.819	0.413	-0.026	-0.014
## NegEmoAge	-0.015	0.012	-1.269	0.204	-0.015	-0.022
## PeNegStresCoa	0.020	0.010	2.014	0.044	0.020	0.018
## PeNegEmoCoa	0.011	0.007	1.632	0.103	0.011	0.010
## T1	0.582	0.106	5.493	0.000	0.582	0.407
## T2	0.523	0.088	5.928	0.000	0.523	0.373

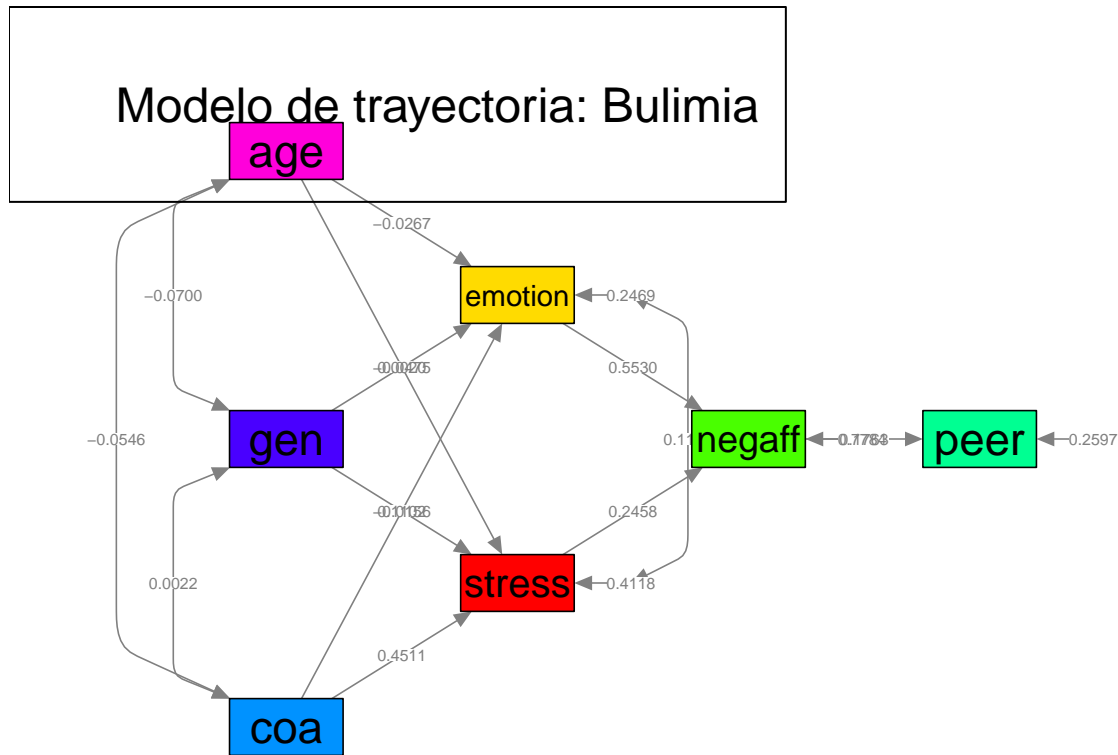
#

# summary(modelo, fit.measures = TRUE, standardized=T)

# #resumen <- summary(modelo, fit.measures = TRUE, standardized=T)

# fitmeasures(modelo)

```
semPaths(sem1, "mod", "par", col=rainbow(7), style="lisrel", layout = "tree2", curve=1.5, curvePivot = TRUE)
legend("topleft", legend=c("Modelo de trayectoria: Bulimia"), col="blue", cex=1.5)
```



## 2. Escribirlo matricialmente

$$\begin{aligned}
 Y_{stres} &= 0Y_{stres} + 0Y_{emo} + 0Y_{neg} + 0Y_{peer} + \gamma_{1,1}X_{coa} + \gamma_{1,2}X_{gen} + \gamma_{1,3}X_{age} + \varsigma_1 \\
 Y_{emo} &= 0Y_{stres} + 0Y_{emo} + 0Y_{neg} + 0Y_{peer} + \gamma_{2,1}X_{coa} + \gamma_{2,2}X_{gen} + \gamma_{2,3}X_{age} + \varsigma_2 \\
 Y_{neg} &= \beta_{1,1}Y_{stres} + \beta_{1,2}Y_{emo} + 0Y_{neg} + 0Y_{peer} + 0X_{coa} + 0X_{gen} + 0X_{age} + \varsigma_3 \\
 Y_{emo} &= 0Y_{stres} + 0Y_{emo} + \beta_{2,1}Y_{neg} + 0Y_{peer} + 0X_{coa} + 0X_{gen} + 0X_{age} + \varsigma_4
 \end{aligned}$$

$$\begin{bmatrix} Y_{stres} \\ Y_{emo} \\ Y_{neg} \\ Y_{peer} \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ \beta_{1,1} & \beta_{1,2} & 0 & 0 \\ 0 & 0 & \beta_{2,1} & 0 \end{bmatrix} \begin{bmatrix} Y_{stres} \\ Y_{emo} \\ Y_{neg} \\ Y_{peer} \end{bmatrix} + \begin{bmatrix} \gamma_{1,1} & \gamma_{1,2} & \gamma_{1,3} \\ \gamma_{2,1} & \gamma_{2,2} & \gamma_{2,3} \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} X_{coa} \\ X_{gen} \\ X_{age} \end{bmatrix} + \begin{bmatrix} \varsigma_1 \\ \varsigma_2 \\ \varsigma_3 \\ \varsigma_4 \end{bmatrix}$$

## 3. Escribir matrices involucradas en modelo

Además, respectivamente, cada matriz presentada con anterioridad puede se expresada como:  $Y = BY + \Gamma x + \zeta$

$$\Psi = \begin{bmatrix} \psi_{1,1} & 0 & 0 & 0 \\ \psi_{2,1} & \psi_{2,2} & 0 & 0 \\ 0 & 0 & \psi_{3,1} & 0 \\ 0 & 0 & 0 & \psi_{4,1} \end{bmatrix} \quad \Phi = \begin{bmatrix} \phi_{1,1} & 0 & 0 \\ \phi_{2,1} & \phi_{2,2} & 0 \\ \phi_{3,1} & \phi_{3,2} & \phi_{3,3} \end{bmatrix}$$



Cabe destacar que  $\Psi$  representa la matriz de correlación entre variables endógenas ( $Y_i$ ). Mientras que la matriz de  $\Phi$  presenta a la correlación entre variables exógenas ( $X_i$ ).

## 4. Ajuste del modelo

La estimación del modelo emplea el método bootstrap, como alternativa a las restricciones del supuesto de normalidad por el método delta. Lo anterior requiere que la muestra esté disponible para realizar el remuestreo (Hallquist, 2019).

Además, se emplean la paquetería *lavaan* como principal instrumento de ajuste computacionales, y se usa la información de la matriz de correlación de Pearson, biserial y tetracórica, según corresponda el tipo de variable. Se tienen 20 grados de libertad, lo que corresponde a la parte de información. A continuación se muestra el código empleado.

```
# CorMid
# comp.cor1 <- getCov(CorMid, sds = NULL, names = c("coa", "age", "gen", "stress", "emotion", "negaff",
# mod1
# sem1 <- sem(mod1, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")

summary(sem1, fit.measures = TRUE, standardized=T)

## lavaan 0.6-8 ended normally after 31 iterations
##
##      Estimator                      ML
##      Optimization method          NLMINB
##      Number of model parameters          20
##
##      Number of observations          316
##
## Model Test User Model:
##
##      Test statistic          81.173
##      Degrees of freedom           8
##      P-value (Chi-square)       0.000
##
## Model Test Baseline Model:
##
##      Test statistic          255.823
##      Degrees of freedom          21
##      P-value          0.000
##
## User Model versus Baseline Model:
##
##      Comparative Fit Index (CFI)          0.688
##      Tucker-Lewis Index (TLI)           0.182
##
## Loglikelihood and Information Criteria:
##
##      Loglikelihood user model (H0)          -2179.133
##      Loglikelihood unrestricted model (H1)    -2138.547
##
##      Akaike (AIC)          4398.267
##      Bayesian (BIC)         4473.382
##      Sample-size adjusted Bayesian (BIC)     4409.947
```

```
##
## Root Mean Square Error of Approximation:
##
##   RMSEA                                0.170
##   90 Percent confidence interval - lower    0.138
##   90 Percent confidence interval - upper    0.205
##   P-value RMSEA <= 0.05                    0.000
##
## Standardized Root Mean Square Residual:
##
##   SRMR                                0.095
##
## Parameter Estimates:
##
##   Standard errors                        Bootstrap
##   Number of requested bootstrap draws      1000
##   Number of successful bootstrap draws      1000
##
## Regressions:
##
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
## stress ~
##   coa      (a)    0.451    0.070    6.436    0.000    0.451    0.331
##   gen      (b)   -0.016    0.072   -0.217    0.828   -0.016   -0.011
##   age      (c)    0.002    0.026    0.074    0.941    0.002    0.004
## emotion ~
##   coa      (e)    0.110    0.055    2.011    0.044    0.110    0.110
##   gen      (f)   -0.048    0.056   -0.845    0.398   -0.048   -0.047
##   age      (g)   -0.027    0.022   -1.243    0.214   -0.027   -0.077
## negaff ~
##   stress   (x)    0.246    0.094    2.609    0.009    0.246    0.175
##   emotion  (y)    0.553    0.118    4.675    0.000    0.553    0.290
## peer ~
##   negaff   (z)    0.176    0.033    5.339    0.000    0.176    0.315
##
## Covariances:
##
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
## .stress ~~
##   .emotion      0.112    0.018    6.116    0.000    0.112    0.352
## coa ~~
##   gen          0.002    0.014    0.161    0.872    0.002    0.009
## gen ~~
##   age        -0.070    0.042   -1.683    0.092   -0.070   -0.097
## coa ~~
##   age        -0.055    0.041   -1.333    0.183   -0.055   -0.076
##
## Variances:
##
##           Estimate  Std.Err  z-value  P(>|z|)  Std.lv  Std.all
## .stress      0.412    0.041   10.154    0.000    0.412    0.890
## .emotion     0.247    0.018   13.841    0.000    0.247    0.979
## .negaff      0.778    0.067   11.622    0.000    0.778    0.848
## .peer        0.260    0.033    7.896    0.000    0.260    0.901
## coa          0.249    0.002  129.447    0.000    0.249    1.000
## gen          0.249    0.003   96.806    0.000    0.249    1.000
## age          2.095    0.132   15.859    0.000    2.095    1.000
```

```
##
## Defined Parameters:
##      Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## NegStresCoa    0.111  0.047  2.378  0.017  0.111  0.058
## NegStresGen   -0.004  0.019 -0.198  0.843 -0.004 -0.002
## NegStresAge    0.000  0.007  0.067  0.946  0.000  0.001
## NegEmoCoa     0.061  0.033  1.821  0.069  0.061  0.032
## NegEmoGen     -0.026  0.032 -0.819  0.413 -0.026 -0.014
## NegEmoAge     -0.015  0.012 -1.269  0.204 -0.015 -0.022
## PeNegStresCoa  0.020  0.010  2.014  0.044  0.020  0.018
## PeNegEmoCoa   0.011  0.007  1.632  0.103  0.011  0.010
## T1            0.582  0.106  5.493  0.000  0.582  0.407
## T2            0.523  0.088  5.928  0.000  0.523  0.373
```

```
#resumen <- summary(modelo, fit.measures = TRUE, standardized=T)
fitmeasures(sem1)
```

```
##      npar      fmin      chisq      df
##      20.000      0.128      81.173      8.000
##      pvalue      baseline.chisq      baseline.df      baseline.pvalue
##      0.000      255.823      21.000      0.000
##      cfi      tli      nnfi      rfi
##      0.688      0.182      0.182      0.167
##      nfi      pnfi      ifi      rni
##      0.683      0.260      0.705      0.688
##      logl      unrestricted.logl      aic      bic
##      -2179.133      -2138.547      4398.267      4473.382
##      ntotal      bic2      rmsea      rmsea.ci.lower
##      316.000      4409.947      0.170      0.138
##      rmsea.ci.upper      rmsea.pvalue      rmr      rmr_nomean
##      0.205      0.000      0.077      0.077
##      srmr      srmr_bentler      srmr_bentler_nomean      crmr
##      0.095      0.095      0.095      0.109
##      crmr_nomean      srmr_mplus      srmr_mplus_nomean      cn_05
##      0.109      0.095      0.095      61.369
##      cn_01      gfi      agfi      pgfi
##      79.210      0.940      0.790      0.269
##      mfi      ecvi
##      0.891      0.383
```

La estimación se los parámetros se muestra a continuación:

## 5. Verifique lo adecuado del ajuste

A fin de verificar el ajuste del modelo, se deben considerar los índices de bondad de ajuste (GoF, por sus siglas en Inglés).

La prueba de la  $\chi^2$  rechaza la hipótesis nula, donde  $H_o : \text{ModeloSíAjusta}$ , es decir que el modelo no ajusta a los datos. Debido a que el Pvalor es mucho menor que la significancia. Sin embargo, el modelo basal es mucho peor que el propuesto.

User Model:

Test statistic 81.173 Degrees of freedom 8 P-value (Chi-square) 0.000

Model Test Baseline Model:

Test statistic 255.823 Degrees of freedom 21 P-value 0.000

**Cuadro 1:** Índices de ajuste del modelo

CFI	TLI	RMSEA	Pvalue	RMSEA	SRMR
0.688	0.182	0.17	0.0		0.095

- CFI: Es el *Comparative Fit Index*, en que este modelo tiene un valor muy pequeño. Por lo que se puede sostener que el modelo es muy malo. Además, para valores "mayor 0.97 es indicativo de un buen ajuste en relación con el modelo de independencia"(Zamora, 2021).
- NNFI ,también conocido como TLI, es decir, "índice de ajuste no normalizado (NNFI), también conocido como el índice de Tucker-Lewis (TLI)". Este modelo tiene un valor muy pequeño, lo que indica que el modelo es malo. Ya que "valores superiores a 0.95 pueden interpretarse como un ajuste aceptable"(Zamora, 2021).
- RMSEA, significa error cuadrático medio de aproximación de la raíz. Donde valores mayores a 0.1, implican valores de ajuste medriocres, por lo que este modelo no es bueno.
- Pvalor RMSEA, implica que el valor puntual de RMSAE sea contenido por un intervalor de confianza del 95
- SRMR, o índice de la raíz del cuadrado medio del residuo estandarizado, "valores de SRMR menores a 0.05 evidencian un buen ajuste y que menores a 0.10 pueden interpretarse como un ajuste aceptable"(Zamora, 2021). Por lo que se puede afirmar que este modelo tiene un ajuste aceptable.

## 6. Interpretar efectos directos, indirectos, totales y concluir

```
mod2v <- '
stress ~ a*coa
emotion ~ e*coa
negaff ~ x*stress + y*emotion
peer ~ z*negaff

emotion ~~ stress
'
```

```
sem3v <- sem(mod2v, data = bd, sample.cov = comp.cor1, sample.nobs = n, se="bootstrap")
summary(sem3v, fit.measures = TRUE, standardized=T)
```

```
## lavaan 0.6-8 ended normally after 20 iterations
##
##      Estimator                      ML
##      Optimization method          NLMINB
##      Number of model parameters      10
##
##      Number of observations          316
##
## Model Test User Model:
##
##      Test statistic                  12.267
##      Degrees of freedom                4
##      P-value (Chi-square)             0.015
```

```
##
## Model Test Baseline Model:
##
##   Test statistic           179.377
##   Degrees of freedom         10
##   P-value                   0.000
##
## User Model versus Baseline Model:
##
##   Comparative Fit Index (CFI)           0.951
##   Tucker-Lewis Index (TLI)             0.878
##
## Loglikelihood and Information Criteria:
##
##   Loglikelihood user model (H0)         -1160.310
##   Loglikelihood unrestricted model (H1)  -1154.176
##
##   Akaike (AIC)                        2340.620
##   Bayesian (BIC)                      2378.177
##   Sample-size adjusted Bayesian (BIC)   2346.460
##
## Root Mean Square Error of Approximation:
##
##   RMSEA                               0.081
##   90 Percent confidence interval - lower 0.032
##   90 Percent confidence interval - upper 0.134
##   P-value RMSEA <= 0.05                0.131
##
## Standardized Root Mean Square Residual:
##
##   SRMR                               0.053
##
## Parameter Estimates:
##
##   Standard errors           Bootstrap
##   Number of requested bootstrap draws      1000
##   Number of successful bootstrap draws      1000
##
## Regressions:
##
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## stress ~
##   coa      (a)    0.451   0.072   6.269   0.000   0.451   0.331
## emotion ~
##   coa      (e)    0.116   0.054   2.131   0.033   0.116   0.115
## negaff ~
##   stress   (x)    0.246   0.098   2.498   0.012   0.246   0.175
##   emotion  (y)    0.553   0.117   4.725   0.000   0.553   0.290
## peer ~
##   negaff   (z)    0.176   0.032   5.451   0.000   0.176   0.315
##
## Covariances:
##
##           Estimate Std.Err z-value P(>|z|) Std.lv Std.all
## .stress ~~
##   .emotion      0.112   0.018   6.255   0.000   0.112   0.350
```

```
##
```

```
## Variances:
```

	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
## .stress	0.412	0.040	10.202	0.000	0.412	0.891
## .emotion	0.249	0.018	13.883	0.000	0.249	0.987
## .negaff	0.778	0.069	11.245	0.000	0.778	0.848
## .peer	0.260	0.033	7.938	0.000	0.260	0.901

```
semPaths(sem3v, "mod", "par", col=rainbow(5), style="lisrel", layout = "tree2", curve=1.5, curvePivot = TR,
legend("topright", legend=c("Modelo de trayectoria: Reajustado"), col="blue", cex=1.1)
```

